

Nicolás Irribarra, USM, Av. España 1680, Valparaíso, Chile, nicolas.irribarra@usm.cl. Mauricio Saldivia, USM, Av. España 1680, Valparaíso, Chile, mauricio.saldivia@usm.cl. Andrea Vasquez, USM, Av. España 1680, andrea.vasquezg@usm.cl. Mario Navarrete, USM, Av. España 1680, Valparaíso, Chile, mario.navarrete.cl. Juan Carlos Lanás, USM, Av. España 1680, Valparaíso, Chile, juan.lanaso@usm.cl. Andrés Fuentes, USM, Av. España 1680, Valparaíso, Chile, andres.fuentes@usm.cl.

Dirección de Transformación Digital
Dirección de Acompañamiento a la Trayectoria Académica-Estudiantil
Dirección General de Tecnologías

Introducción

El Sistema de Acompañamiento a la Trayectoria Estudiantil (SAT-E), implementado en la Universidad Técnica Federico Santa María, tiene como objetivo reducir la deserción estudiantil y promover la titulación oportuna en la educación superior. A través del uso de modelos predictivos y análisis de datos, el SAT-E identifica las necesidades de apoyo de los estudiantes a lo largo de su trayectoria académica. Con un enfoque proactivo y personalizado, el sistema optimiza el acompañamiento académico y psicoeducativo, garantizando una mejor asignación y uso de los recursos institucionales.

Objetivos

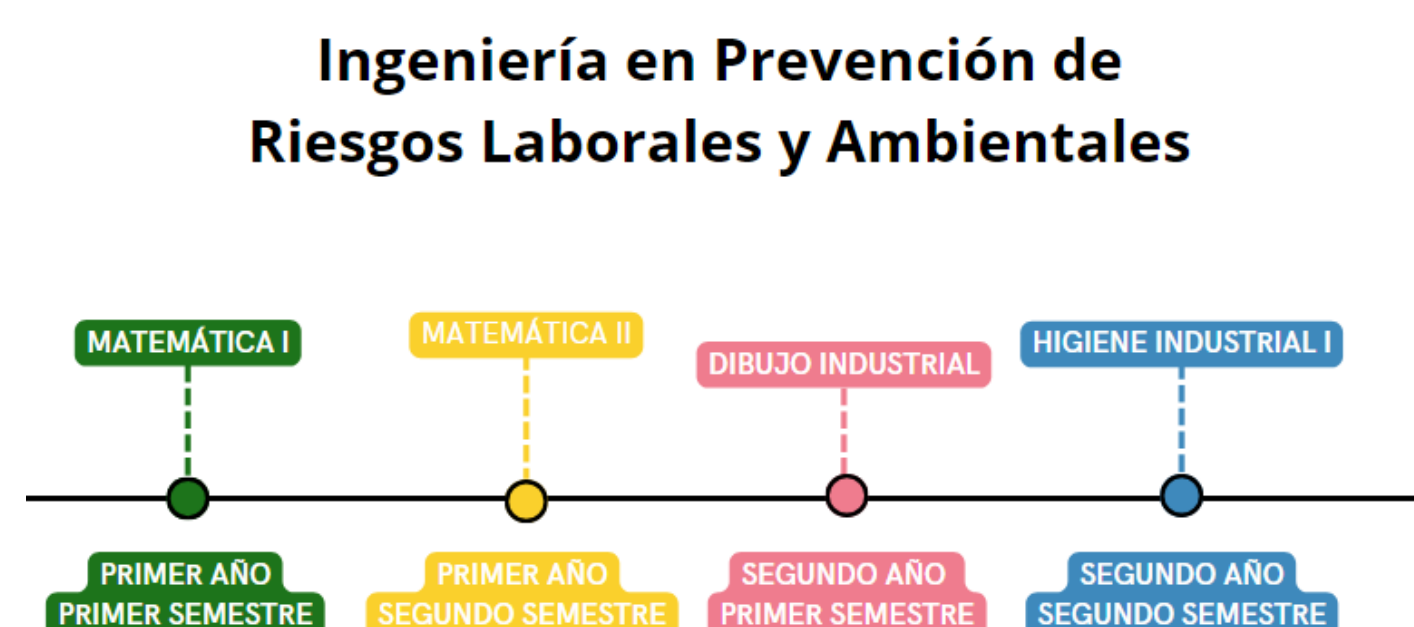
- Consolidar el proceso de seguimiento a la trayectoria universitaria, en su planificación, implementación, evaluación y mejora continua.
- Articular e implementar acciones de nivelación y acompañamiento académico y psicoeducativo durante los primeros años, en coordinación con los demás servicios estudiantiles.
- Reducir la deserción y mejorar la titulación, mediante la detección temprana de estudiantes en riesgo y la aplicación de intervenciones específicas para aumentar la retención y la titulación oportuna.

Metodología

[1] Identificación y consolidación de datos históricos relevantes desde sistemas transaccionales, e integración en un data warehouse.


[2] Limpieza y preparación de los datos para los análisis, con segmentación según características relevantes.

[3] Aplicación de métodos estadísticos para identificar las asignaturas determinantes en la continuidad del estudiante.



[4] Implementación de modelos predictivos de clasificación:

- XGBoost: modelo de aprendizaje basado en árboles de decisión.
- Red Neuronal: modelo de aprendizaje basado en capas de neuronas interconectadas.




[5] Generación de alertas de riesgo:

- Los grupos de riesgo se generan mediante un modelo de optimización que maximiza la diferencia de medianas de una variable, como la nota final de los estudiantes.
- Existen 5 alertas actualmente, a saber: Alerta 0, que es de entrada, previo al inicio de clases. Alerta 1, a mitad de semestre con notas parciales para riesgo de reprobación de asignatura crítica. Alerta 2, riesgo de deserción al primer año. Alerta 2.2, riesgo de deserción de segundo año. Alerta T0, titulación oportuna para Carreras Técnicas.



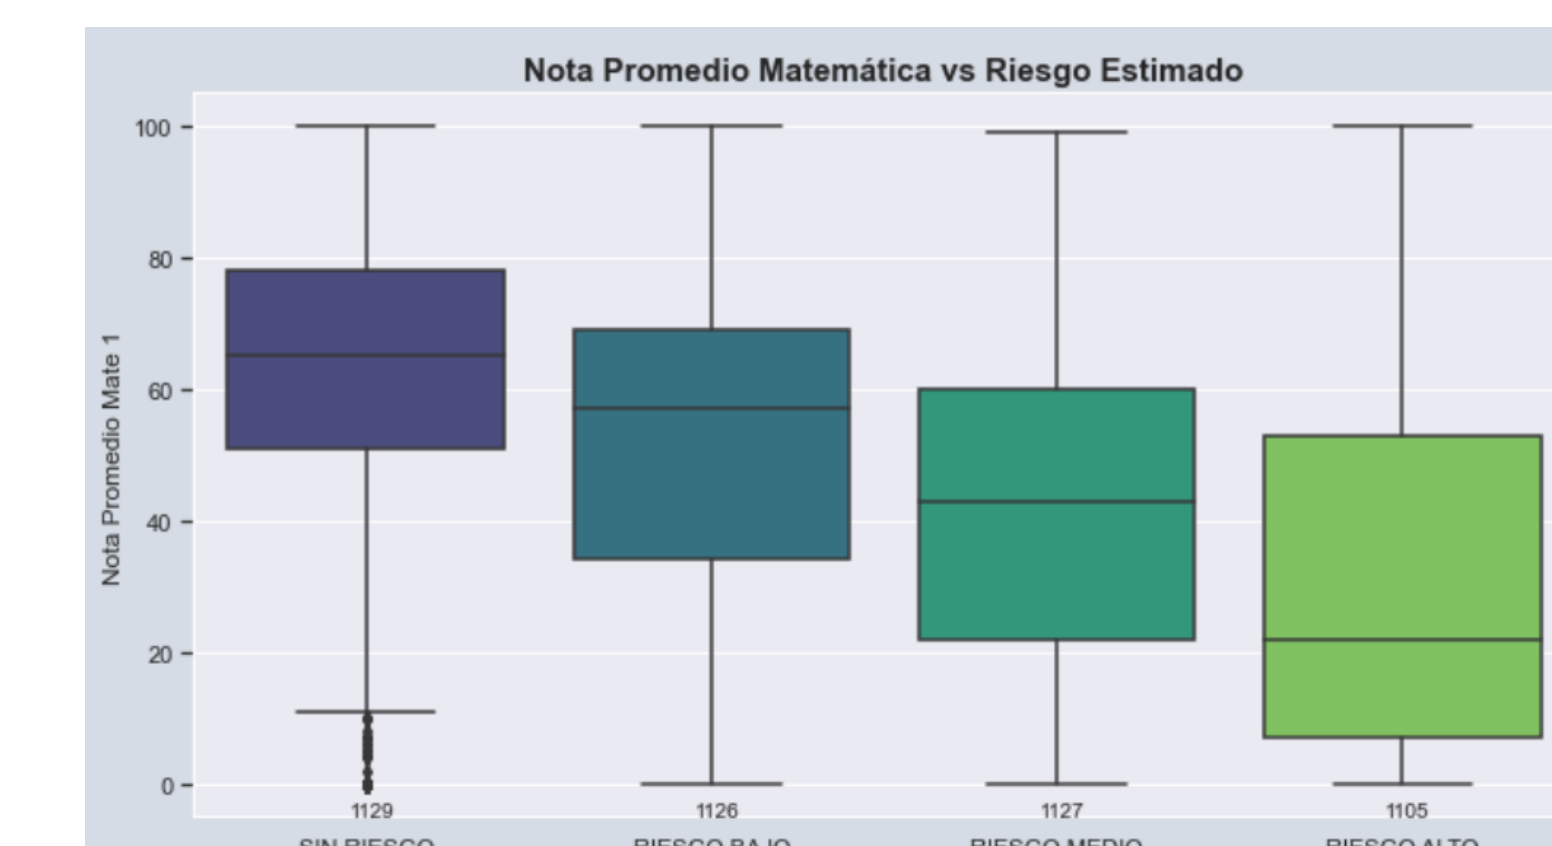
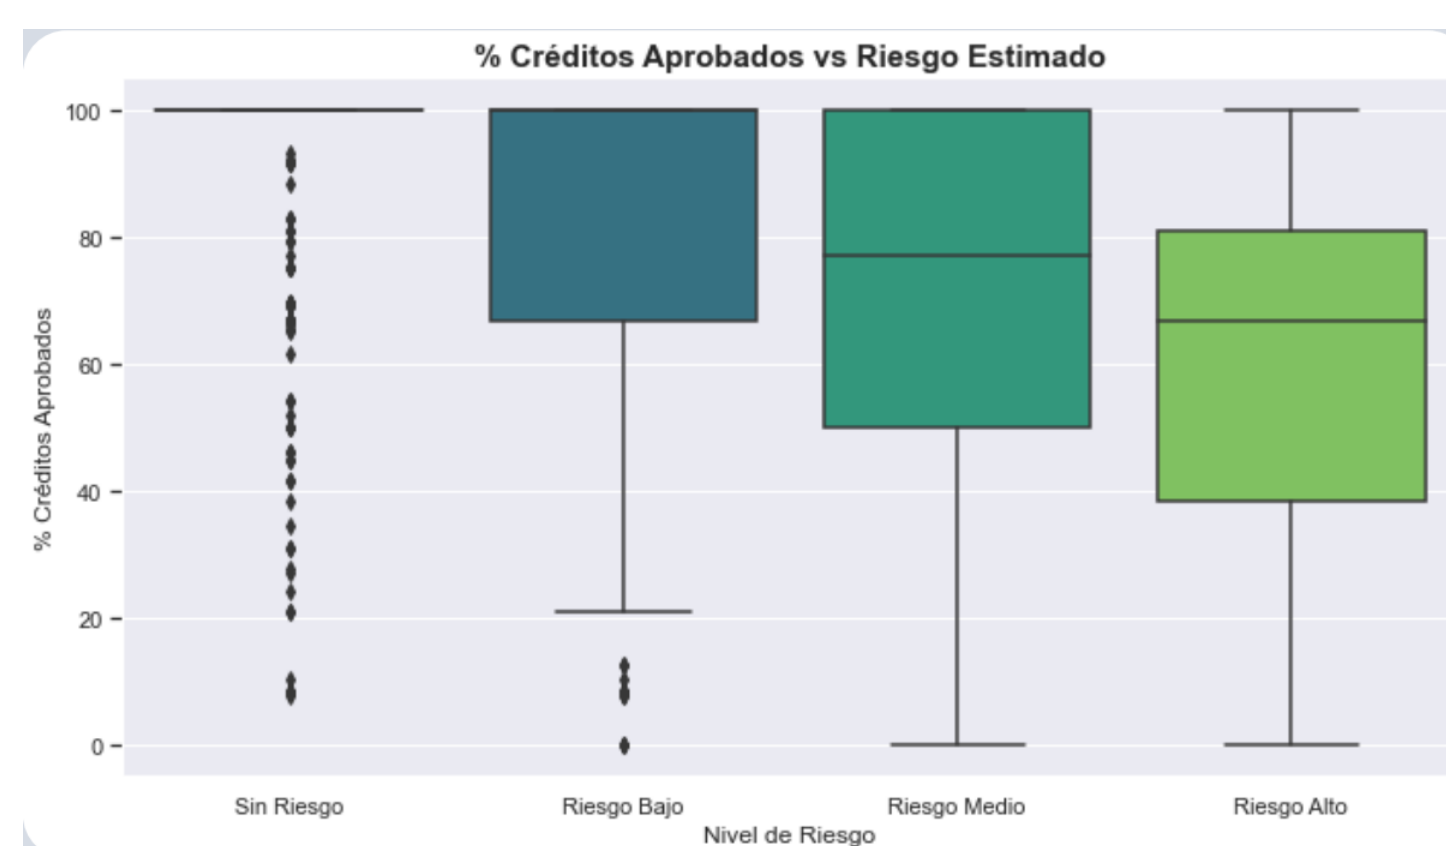
[6] Despliegue de las alertas en reportes de inteligencia de negocios, usando Power BI, con distintos perfiles de visualización.

Resultados y discusiones



	N	Precisión	Recall	F1-Score
Reprueba	655	0.60	0.64	0.62
Aprueba	1028	0.76	0.73	0.74

Tramo	N° de estudiantes	E [% reprobación]	%Reprobados	% Créd. aprobados
Sin riesgo	442	6.2	14.4	92.4
Riesgo bajo	484	28.0	34.1	82.4
Riesgo medio	380	60.8	49.5	79.2
Riesgo alto	377	89.2	72.9	58.3



- El 75% de los estudiantes clasificados en la menor categoría de riesgo finalizaron el semestre con una tasa de aprobación de créditos superior al 80%.
- El modelo predice correctamente la condición de aprobación en asignaturas críticas en el 71% de los casos.
- Más del 50% de las autoridades, jefes de carrera y profesionales de acompañamiento utilizan los reportes de BI para tomar decisiones basadas en datos.

Conclusiones

- La consolidación de datos históricos en el data warehouse facilitó el acceso y uso de la información para el desarrollo del sistema, tanto en la modelación como en la reportería de BI.
- El modelo XGBoost logró más del 85% de precisión en la identificación de estudiantes en riesgo.
- Las alertas de riesgo mejoraron la asignación de recursos institucionales, permitiendo priorizar a los estudiantes con mayor riesgo.
- El sistema ofrece un enfoque integral que permite un seguimiento más efectivo del progreso de los estudiantes, incluyendo la evaluación del riesgo académico.
- El sistema se ha consolidado como un habilitador clave para la toma de decisiones basadas en datos dentro de la institución.

Referencias

- "Educational Data Mining and Learning Analytics" de Cristóbal Romero y Sebastián Ventura.
- "Predictive Analytics in Higher Education" de Daniel T. Larose y Chantal D. Larose.
- "Early Warning Systems for Students in Higher Education: A Review" de diversos autores. Publicado en Journal of Educational Technology & Society.

Agradecimientos:

DATA-E agradece el apoyo financiero de MINEDUC a través del Proyecto FSM 22101



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA